

第四章：参数估计

中国科学技术大学

第四章：参数估计

4.4	点估计	2
4.4.1	矩估计方法	2
4.4.2	最大 (极大) 似然估计方法	10

参数估计问题:

- 总体: $X \sim f_{\theta}(x)$, f 形式已知, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数
- 样本: X_1, \dots, X_n

利用样本对参数 θ 的作出估计或估计它们的某个已知函数 $g(\theta)$.

- **点估计**: 用样本的一个函数 $T(X_1, \dots, X_n)$ 去估计 $g(\theta)$
- **区间估计**: 用一个区间 (区域) 去估计 $g(\theta)$

4.4 点估计

根据样本 X_1, \dots, X_n 来估计参数 θ , 就是要构造适当的统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$. 当有了样本 X_1, \dots, X_n 的值后, 就代入 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 中算出一个值, 用来作为 θ 的估计值. 为这样特定目的而构造的统计量 $\hat{\theta}$ 叫做 θ 的**估计量**. 由于参数 θ 是数轴上的一个点, 用 $\hat{\theta}$ 估计 θ , 等于用一个点去估计另一个点, 所以这样的估计叫做**点估计**.

求点估计的方法有多种, 下面介绍两种点估计方法:

4.4.1 矩估计方法

矩方法追溯到 19 世纪的**Karl Pearson**. 矩方法是基于一种简单的“替换”思想建立起来的一种估计方法. 其基本思想是用样本矩估计总体矩. 由大数律, 如果未知参数和总体的某个 (些) 矩有关系, 我们很自然的来构造未知参数的估计。

回忆一下以前关于矩的记法：

$$\text{样本}k\text{阶矩: } a_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

$$\text{总体}k\text{阶矩: } \alpha_k = EX^k \quad \mu_k = E(X - EX)^k$$

因此在 k 阶矩存在的情况下，根据大数律有

$$a_k \xrightarrow{p} \alpha_k, \quad m_k \xrightarrow{p} \mu_k$$

从而我们可以使用 a_k, m_k 分别估计 α_k, μ_k ，进而得到 θ 的估计. 介绍如下：假设总体 X 包含 k 个未知参数 $\theta = (\theta_1, \dots, \theta_k)$ ，由方程组

$$\begin{cases} \alpha_1 = f_1(\theta_1, \dots, \theta_k) \\ \vdots \\ \alpha_k = f_k(\theta_1, \dots, \theta_k) \end{cases}$$

反解得到

$$\begin{cases} \theta_1 = g_1(\alpha_1, \dots, \alpha_k) \\ \vdots \\ \theta_k = g_k(\alpha_1, \dots, \alpha_k) \end{cases}$$

将其中的总体矩用相应的样本矩代替,则我们可以得到参数 $\theta_1, \dots, \theta_k$ 的一个估计:

$$\begin{cases} \hat{\theta}_1 = g_1(a_1, \dots, a_k) \\ \vdots \\ \hat{\theta}_k = g_k(a_1, \dots, a_k) \end{cases}$$

若要估计参数 $\theta_1, \dots, \theta_k$ 的某函数 $g(\theta_1, \dots, \theta_k)$, 则用 $g(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 去估计它.

这里我们用的都是原点矩 α_k , 当然也可以使用中心矩 μ_k , 或者两个都使用。在这种情况下, 只需要把相应的总体矩换成样本矩。我们称这种估计方法为矩估计法, 得到的估计量称为矩估计量。**矩估计方法应用的原则是：能用低阶矩处理的就不用高阶矩。**

矩估计法的优点是简单易行, 有些情况下不需要事先知道总体是什么分布. 缺点是, 当总体类型已知时, 没有充分利用分布提供的信息. 一般场合下, 矩估计量不具有唯一性.

投掷一枚硬币, 为了解正面出现的概率, 现独立重复的投掷 n 次, 用 X_1, \dots, X_n 表示投掷结果. 显然此时总体 X 的分布为 $B(1, p)$, p 为感兴趣的量. 而 X_1, \dots, X_n 为样本, 则求参数 p 的矩估计量。

[↑Example](#)

[↓Example](#)

解: 由于 $EX = p$, 而样本均值 \bar{X} 收敛到总体均值 EX , 因此 p 的一个矩估计量为 $\hat{p} = \bar{X}$.

↑Example

为考察某种考试成绩分布情况, 使用正态分布 $N(a, \sigma^2)$ 来作为总体 X 的分布. 现在从中随机调查 n 个人, 即样本为 X_1, \dots, X_n . 试求参数 a, σ^2 的矩估计量.

↓Example

解: 由于

$$EX = a, \quad \text{Var}(X) = \sigma^2$$

所以 a, σ^2 的一个矩估计量为

$$\hat{a} = \bar{X}, \quad \hat{\sigma}^2 = m_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

我们知道 $ES^2 = \sigma^2$, 因此, σ^2 的另一个矩估计量为 $\hat{\sigma}^2 = S^2$.

设 (X_1, X_2, \dots, X_n) 是从均匀分布总体 $X \sim U(\theta_1, \theta_2)$ 中抽取的一个样本, 求 $\hat{\theta}_1, \hat{\theta}_2$

[↑Example](#)

[↓Example](#)

解: 由于 $EX = (\theta_1 + \theta_2)/2, \mu_2 = \text{Var}(X) = (\theta_2 - \theta_1)^2/12$, 用 \bar{X} 代替 EX, S^2 代替 μ_2 , 解方程组, 得

$$\hat{\theta}_1 = \bar{X} - \sqrt{3}S, \quad \hat{\theta}_2 = \bar{X} + \sqrt{3}S$$

设 (X_1, X_2, \dots, X_n) 是从总体 $X \sim F$ 中抽取的一个样本, 求偏度系数 $\beta_1 = \mu_3/\mu_2^{3/2}$, 峰度系数 $\beta_2 = \mu_4/\mu_2^2$ 的矩估计。

[↑Example](#)

[↓Example](#)

解: 由于偏度系数和峰度系数都是总体中心矩的函数, 所以可以用样本中心矩代替总体中心矩得到, 即

$$\hat{\beta}_1 = m_3/m_2^{3/2}, \quad \hat{\beta}_2 = m_4/m_2^2$$

设 (X_1, X_2, \dots, X_n) 是从正态总体 $X \sim N(\mu, \sigma^2)$ 中抽取的一个样本, 求概率 $P(X > 3)$ 的矩估计。

[↑Example](#)

[↓Example](#)

解: 由于

$$P(X > 3) = 1 - \Phi\left(\frac{3 - \mu}{\sigma}\right)$$

这是 μ, σ^2 的函数, 用 \bar{X} 代替 μ , S 代替 σ , 得

$$\hat{P}(X > 3) = 1 - \Phi\left(\frac{3 - \bar{X}}{S}\right)$$

4.4.2 最大 (极大) 似然估计方法

最大似然方法到目前为止应用最广的的点估计方法. 这种方法是基于如下的看法:

设样本 $X = (X_1, \dots, X_n)$ 有概率函数

$$f(x; \theta) = f(x; \theta_1, \dots, \theta_k)$$

Definition

这里参数 $\theta = (\theta_1, \dots, \theta_k) \in \Theta$, $x = (x_1, \dots, x_n)$ 为样本 X 的观察值. 当固定 x 时把 $f(x; \theta)$ 看成为 θ 的函数, 称为似然函数, 常记为 $L(x; \theta)$ 或 $L(\theta)$.

当固定参数 θ 时, $f(x; \theta)$ 可以看成是得到样本观察值 x 的可能性, 这样, 当把参数 θ 看成变动时, 也就得到“在不同的 θ 值下能观察到 x 的可能性大小, 即 $L(x; \theta)$ ”; 由于我们已经观察到了 x , 所以

使得能观察到 x 的可能性 $L(x; \theta)$ 最大的 θ 值, 看起来应该最像未知的 θ 。这个 θ 的值即称为 θ **最大似然估计值**(看上去最有可能的)。我们先看一个例子:

从鱼池里随机捕捞 500 条鱼, 做好记号后重新放入鱼池中, 待充分混合后再捕捞 1000 条鱼, 结果发现其中有 72 条带有记号. 试问鱼池中可能有多少条鱼.

[↑Example](#)

[↓Example](#)

解: 先将问题一般化. 设池中有 N 条鱼, 其中 r 条做好记号. 鱼在鱼池里均匀. 随机捕捞 s 条, 发现 x 条有记号. 用上述信息来估计 N . 用 X 表示捕捞的 s 条鱼中带记号鱼的数目, 则

$$P(X = x) = \frac{C_{N-r}^{s-x} C_r^x}{C_N^s}.$$

目前发现在捕捞的 s 条鱼中有记号的鱼 x 条, 要寻求 N 取何值时, 使得观察到这个事件 $\{X = x\}$ 的可能性最大. 即 x 是固定的, N 是变化的, 记 $p(x; N) = P(X = x)$. 因为

$$g(N) := \frac{p(x; N)}{p(x; N-1)} = \frac{(N-s)(N-r)}{N(N-r-s+x)} = \frac{N^2 - N(s+r) + rs}{N^2 - N(r+s) + Nx},$$

当 $rs > Nx$ 时, $g(N) > 1$; $rs < Nx$ 时, $g(N) < 1$. 所以 $P(X = x)$ 在 $N = \frac{rs}{x}$ 附近达到最大, 注意到 N 只能取正整数, 故 N 的最可能的估计即最大似然估计为

$$\hat{N} = \left\lfloor \frac{rs}{x} \right\rfloor.$$

其中 $\lfloor \cdot \rfloor$ 表示下取整, 即小于该值的最大整数. 将题目中的数字代入,

$$\hat{N} = \left\lfloor \frac{500 \times 1000}{72} \right\rfloor = 6944.$$

即鱼池中的总的鱼数为 6694 条.

现给出最大似然估计的一般性定义:

设 $X = (X_1, \dots, X_n)$ 为从具有概率函数 $f_\theta(x)$ 的总体中抽取的样本, θ 为未知参数或者参数向量. $x = (x_1, \dots, x_n)$ 为样本的观察值. 若在给定 x 时, 值 $\hat{\theta} = \hat{\theta}(x)$ 满足下式

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(x; \theta)$$

Definition

则称 $\hat{\theta}$ 为参数 θ 的最大似然估计值, 而 $\hat{\theta}(X)$ 称为参数 θ 的最大似然估计量. 若待估参数为 θ 的函数 $g(\theta)$, 则 $g(\theta)$ 的最大似然估计量为 $g(\hat{\theta})$.

求最大似然估计值相当于求似然函数的最大值。在简单样本的情况下,

$$L(x; \theta) = \prod_{i=1}^n f_{\theta}(x_i)$$

而把似然函数的对数 $l(\theta) = \log L(\theta)$ 称为对数似然函数 (这是由于在一些情况下, 处理对数似然函数更方便)

当似然函数对变量 θ 单调时, 我们可以容易得到其最大值点. 反之当似然函数为非单调函数且对变量 θ 可微分时, 我们可以求其驻点: 令

$$\frac{dl(\theta)}{d\theta} = 0 \quad (\text{或者} \frac{dL(\theta)}{d\theta} = 0)$$

当 θ 为多维时, 比如 $\theta = (\theta_1, \dots, \theta_k)$ 时令

$$\frac{\partial l(\theta)}{\partial \theta_i} = 0 \quad (\text{或者} \frac{\partial L(\theta)}{\partial \theta_i} = 0) \quad i = 1, \dots, k$$

然后判断此驻点是否是最大值点。

设 X_1, \dots, X_n 为从总体 $X \sim N(a, \sigma^2)$ 中抽取的样本, 求参数 a, σ^2 的最大似然估计量。

[↑Example](#)

[↓Example](#)

解: 易得对数似然函数为

$$l(a, \sigma^2) = c - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2 - \frac{n}{2} \log(\sigma^2)$$

其中 c 是与参数无关的常数. 令

$$\begin{cases} \frac{\partial l(a, \sigma^2)}{\partial a} = 0 \\ \frac{\partial l(a, \sigma^2)}{\partial \sigma^2} = 0 \end{cases} \Rightarrow \begin{cases} a = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \\ \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 \end{cases}$$

容易验证此驻点是唯一的最大值点, 因此得到 a, σ^2 的最大似然估计量:

$$\hat{a} = \bar{X} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

设总体 X 服从 $[a, b]$ 上的均匀分布, $a < b$, 求参数 a, b 的最大似然估计.

[↑Example](#)

[↓Example](#)

解: 易得似然函数为

$$L(a, b) = \frac{1}{(b-a)^n} \prod_{j=1}^n I(a \leq x_j \leq b) = \frac{1}{(b-a)^n} I(a \leq x_{(1)} \leq x_{(n)} \leq b).$$

于是对任何满足条件 $a \leq x_j \leq b$ 的 a, b 都有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$

即似然函数 $L(a, b)$ 在 $a = x_{(1)}, b = x_{(n)}$ 时取到最大值. 于是 a, b 的最大似然估计量为 $\hat{a} = X_{(1)}, \hat{b} = X_{(n)}$.

设 X_1, \dots, X_n 为从具有如下形式密度的总体中抽取的样本:

[↑Example](#)

$$f(x; a, b) = \begin{cases} \frac{1}{b} \exp\{-\frac{x-a}{b}\} & , x > a \\ 0 & , x \leq a \end{cases}$$

求参数 a, b 的最大似然估计量.

[↓Example](#)

解：易得似然函数为

$$L(a, b) = \prod_{i=1}^n f(x_i; a, b) = \frac{1}{b^n} \exp\left\{-\frac{1}{b} \sum_{i=1}^n (x_i - a)\right\} I(x_{(1)} > a)$$

在固定 b 时，显然似然函数为 a 的单调增函数，因此 $L(a)$ 的驻点为 $\hat{a} = x_{(1)}$ 。再令 $\frac{\partial L(a, b)}{\partial b} = 0$ ，得到 $b = \frac{1}{n} \sum_{i=1}^n (x_i - x_{(1)})$ ，容易验证此解是最大值点。从而得到 a, b 的最大似然估计量：

$$\begin{cases} \hat{a} = X_{(1)} \\ \hat{b} = \frac{1}{n} \sum_{i=1}^n (X_i - X_{(1)}) \end{cases}$$

设总体 X_1, \dots, X_n 服从 0-1 分布 $B(1, p)$, $0 < p < 1$, 求参数 p 的最大似然估计.

↑Example

↓Example

解: 似然函数为

$$L(p) = \prod_{i=1}^n P(X_i = x_i) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

从而令 $\frac{\partial \log L(p)}{\partial p} = 0$ 得到

$$\frac{\sum x_i}{p} = \frac{n - \sum x_i}{1-p}$$

因此 p 的似然估计为

$$\hat{p} = \frac{\sum_{i=1}^n X_i}{n}.$$

设总体 X_1, \dots, X_n 服从柯西分布 $f(x) = \frac{1}{\pi} \frac{1}{1+(x-\theta)^2}$, $x \in R, \theta \in R$, 求参数 θ 的最大似然估计.

↑Example

↓Example

解: 因为柯西分布不存在矩, 因此矩方法不适用. 其对数似然函数为

$$l(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i) = \sum_{i=1}^n [-\log \pi - \log(1 + (x_i - \theta)^2)]$$

从而令 $\frac{\partial l(\theta)}{\partial \theta} = 0$ 得到

$$\sum_{i=1}^n \frac{2(x_i - \theta)}{1 + (x_i - \theta)^2} = 0$$

此方程没有显式解, 可以使用数值方法求解. 使用起来不太方便, 因此在应用中, 考虑到柯西分布的对称性, 使用样本中位数来估计 θ .

设 X_1, \dots, X_n 为从如下分布中抽取的简单样本, 求 θ 的最大似然估计.

$$f(x) = \frac{1}{x!(2-x)!} [\theta^x (1-\theta)^{2-x} + \theta^{2-x} (1-\theta)^x], \quad x = 0, 1, 2; \quad \theta \in (0, \frac{1}{2})$$

解: 由题设知 $f(x)$ 为离散型, 其分布律为

X	0	1	2
P	$\frac{1}{2}[(1-\theta)^2 + \theta^2]$	$2\theta(1-\theta)$	$\frac{1}{2}[(1-\theta)^2 + \theta^2]$

若直接从此分布出发, 则不能得到 θ 的最大似然估计的显式表达。为此, 我们重新参数化, 记 $\eta = 2\theta(1-\theta)$. 则由题设知 $\eta < 1/2$. 则

X	0	1	2
P	$\frac{1}{2}(1-\eta)$	η	$\frac{1}{2}(1-\eta)$

再记 $n_i = \#\{X_1, \dots, X_n \text{ 中等于 } i \text{ 的个数}\}$, $i = 0, 1, 2$, 则得到似然函数为

$$L(\eta) = \left(\frac{1}{2}(1-\eta)\right)^{n_0} \eta^{n_1} \left(\frac{1}{2}(1-\eta)\right)^{n_2} = \left(\frac{1}{2}(1-\eta)\right)^{n-n_1} \eta^{n_1}$$

求解并注意 η 的上界即得到 η 的最大似然估计为

$$\hat{\eta} = \min\left\{\frac{n_1}{n}, \frac{1}{2}\right\}$$

再由 $\theta = \frac{1-\sqrt{1-2\eta}}{2}$ 得到 θ 的最大似然估计为

$$\hat{\theta} = \frac{1 - \sqrt{1 - 2\hat{\eta}}}{2}$$