4.4 区间估计

金百锁

第四章:参数估计

4.4	区间估	计.									1
	4.4.1	置信	区间								2
	4.4.2	置信	界.								12
	4.4.3	确定	样本	大八							14

4.4 区间估计

对于一个未知量,人们在测量和计算时,常不以得到近似值为满足,还需要估计误差,及要求知道近似值的精确程度(亦即所求真值所在的范围). 类似的,对于未知的参数 θ ,除了求出它的点估计 $\hat{\theta}$ 外,我们还希望估计出一个范围,并希望知道这个范围包含参数 θ 真值得可信程度. 这样的范围通常以区间形式给出,同时还给出此区间包含真值的可信程度. 这种形式的估计称为区间估计.

比如你估计月花费支出是 500, 我们相信多少会有误差, 但是误差 有多大? 单从你提出的 500 这个数字还给不出什么信息, 若你给出估 计支出是 400-600 之间, 则人们相信你在作出这估计时, 已把可能出现的误差考虑到了, 多少给人们以更大的信任感. 因此区间估计也是常用的一种估计方式.

[↑]Example

↓Example

现在最流行的一种区间估计理论是 J. Neyman 在上世纪 30 年代建立起来的. 他的理论的基本概念很简单,为表达方便,我们暂时假定总体分布只包含一个未知参数 θ , 且要估计的就是 θ 本身. 如果总体分布中包含若干位置参数 $\theta_1, \cdots, \theta_k$,而要估计的是 $g(\theta_1, \cdots, \theta_k)$,则基本概念和方法并无不同. 这在后面的例子里可以看出.

4.4.1 置信区间

Neyman 建立起来的区间估计也叫**置信区间**,字面上的意思是: **对该区间能包含未知参数** θ **可置信到何种程度**.

假设 X_1, \dots, X_n 是从该总体中抽取的样本, 所谓 (一维未知) θ 的区间估计, 就是要

- 寻求统计量 $\underline{\theta}(X_1,\cdots,X_n)<\bar{\theta}(X_1,\cdots,X_n)$ 所构成的区间 $[\underline{\theta},\bar{\theta}]$.
- 该区间满足一定的要求

不难理解,这里有两个要求

• θ 以很大概率被包含在区间 $[\underline{\theta}, \overline{\theta}]$ 内, 也就是说

$$P_{\theta}(\underline{\theta} \le \theta \le \bar{\theta}) = 1 - \alpha$$

尽可能大, 即要求估计尽量可靠.

• 估计的精度要尽可能高,比如要求区间 $[\underline{\theta}, \overline{\theta}]$ 要尽可能的短,或者某种能体现这个要求的其他准则。

比如估计一个人的年龄,如 [30,35],我们自然希望这个人的年龄有很大把握在这个区间之内,并且希望这个区间不能太长. 如果估计是 [10,90],当然可靠了,但是精度太差,用处不大.

但这两个要求是相互矛盾的,因此区间估计的原则是在已有的样本资源限制下,找出更好的估计方法以尽量提高可靠性和精度。Neyman 提出了广泛接受的准则: 先保证可靠性,在此前提下尽可能提高精度。为此、引入如下定义:

设总体分布 $F(x,\theta)$ 含有一个或多个未知的参数 $\theta,\theta\in\Theta$, 对给定的值 $\alpha,(0<\alpha<1)$, 若由样本 X_1,\cdots,X_n 确定的两个统计量 $\bar{\theta}=\bar{\theta}(X_1,\cdots,X_n)$ 和 $\underline{\theta}=\underline{\theta}(X_1,\cdots,X_n)$, 满足

$$P_{\theta}(\underline{\theta} \le \theta \le \overline{\theta}) = 1 - \alpha \quad \forall \ \theta \in \Theta$$

Definition

称 $1-\alpha$ 为置信系数或置信水平, 而称 $[\underline{\theta}, \bar{\theta}]$ 为 θ 的置信水平为 $1-\alpha$ 的置信区间。

置信区间就是在给定的置信水平之下, 去寻找有优良精度的区间。

一般, 我们首先寻求参数 θ 的一个估计 (多数是基于其充分统计量构造的), 然后基于此估计量构造参数 θ 的置信区间, 介绍如下:

- 1. 枢轴变量法 设待估参数为 $g(\theta)$,
 - 1. 找一个与待估参数 $g(\theta)$ 有关的统计量 T, 一般是其一个良好的 点估计 (多数是通过极大似然估计构造);
 - 2. 设法找出 T 与 $g(\theta)$ 的某一函数 $S(T, g(\theta))$ 的分布, 其分布 F 要与参数 θ 无关 (S 即为枢轴变量);
 - 3. 对任何常数 a < b, 不等式 $a \le S(T, g(\theta)) \le b$ 要能表示成等价的形式 $A \le g(\theta) \le B$, 其中 A, B 只与 T, a, b 有关而与参数无关;
 - 4. 取分布 F 的上 $\alpha/2$ 分位数 $\omega_{\alpha/2}$ 和上 $(1-\alpha/2)$ 分位数 $\omega_{1-\alpha/2}$, 有 $F(\omega_{\alpha/2}) F(\omega_{1-\alpha/2}) = 1 \alpha$. 因此

$$P(\omega_{1-\alpha/2} \le S(T, g(\theta)) \le \omega_{\alpha/2}) = 1 - \alpha$$

由 3 我们就可以得到所求的置信区间.

设 X_1, \dots, X_n 为从正态总体 $N(\mu, \sigma^2)$ 中抽取得样本,求参数 μ, σ^2 的 $1 - \alpha$ 置信区间。

↓Example

解:由于 μ, σ^2 的估计 \bar{X}, S^2 满足

$$T_1 = \sqrt{n}(\bar{X} - \mu)/S \sim t_{n-1}$$

 $T_2 = (n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$

所以 T_1, T_2 就是我们所要寻求的枢轴变量,从而易得参数 μ, σ^2 的 $1-\alpha$ 置信区间分别为

$$\left[\bar{X} - \frac{1}{\sqrt{n}} St_{n-1}(\alpha/2), \bar{X} + \frac{1}{\sqrt{n}} St_{n-1}(\alpha/2) \right]$$

$$\left[\frac{(n-1)S^2}{\chi_{n-1}^2(\alpha/2)}, \frac{(n-1)S^2}{\chi_{n-1}^2(1-\alpha/2)} \right].$$

_ ↑Example

设 X_1, \cdots, X_n 为从正态总体 $N(\mu_1, \sigma_1^2)$ 中抽取得样本, Y_1, \cdots, Y_m 为从正态总体 $N(\mu_2, \sigma_2^2)$ 中抽取得样本,两组样本相互独立。求参数 $\mu_1 - \mu_2, \sigma_1^2/\sigma_2^2$ 的 $1 - \alpha$ 置信区间。

↓Example

解: 方法完全类似于前面的例子,由于 $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2$ 的估计分别 为 $\bar{X}, \bar{Y}, S_X^2, S_Y^2$,且注意到 $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m})$, $(n-1)S_X^2/\sigma_1^2 \sim \chi_{n-1}^2$ 以及 $(m-1)S_X^2/\sigma_1^2 \sim \chi_{m-1}^2$,结合两组样本的独立性可知

$$\frac{S_Y^2}{S_X^2} \frac{\sigma_2^2}{\sigma_1^2} \sim F(m-1, n-1)$$

从而可得 σ_X^2/σ_Y^2 的置信区间. 对 $\mu_1 - \mu_2$ 的置信区间, 当 σ_X^2, σ_Y^2 已 知或者相等但未知情形, 容易得到其置信区间; 当两者不全已知且不相等时, 不存在 $\mu_X - \mu_Y$ 的精确置信区间 (Behrens-Fisher problem).

2. 大样本法

大样本法就是利用极限分布,以建立枢轴变量。通过以下例子说明:

某事件 A 在每次实验中发生的概率都是 p, 作 n 次独立的实验, 以 Y_n 记 A 发生的次数。求 p 的 $1-\alpha$ 置信区间。

_ ↑Example

↓Example

解: 设 n 比较大,令 q=1-p,则由中心极限定理知,近似有 $(Y_n-np)/\sqrt{npq}\sim N(0,1)$,从而 $(Y_n-np)/\sqrt{npq}$ 可以作为枢轴变量。由

$$P(-u_{\alpha/2} \le (Y_n - np) / \sqrt{npq} \le u_{\alpha/2}) \approx 1 - \alpha \tag{*}$$

可以等价表示成

$$P(A \le p \le B) \approx 1 - c$$

其中 A, B 为方程

$$(Y_n - np)/\sqrt{npq} = u_{\alpha/2}$$

的解,即

$$A,B = \frac{n}{n + u_{\alpha/2}^2} \left[\hat{p} + \frac{u_{\alpha/2}^2}{2n} \pm u_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{u_{\alpha/2}^2}{4n^2}} \right]$$

A 取负号, B 取正号, $\hat{p} = Y_n/n$ 。由于 (*) 式只是近似成立,故区间估计也只是近似成立, 当 n 较大时才相去不远。详细的说明参见课本 p203。我们还可以先假定方差是"已知"的,最后再将其估计,得到如下 Wald 置信区间:

$$\hat{p} \pm u_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}.$$

Wald 置信区间:

$$\hat{p} \pm u_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}.$$

设 x_1, \dots, x_n 是从 Poisson 总体 X 中抽取的一个简单随机样本,求 λ 的区间估计。

↓Example

解: 在 Poisson 总体中, $EX = \lambda$, $Var(\bar{X}) = \lambda/n$. 由中心极限定理, 近似有

$$\sqrt{n}(\bar{X} - \lambda)/\sqrt{\lambda} \sim N(0, 1),$$

所以 $\sqrt{n}(\bar{X}-\lambda)/\sqrt{\lambda}$ 可以作为枢轴变量。仿前例做法, 得置信区间为

$$-u_{\alpha/2} \le \sqrt{\frac{n}{\lambda}}(\bar{x} - \lambda) \le u_{\alpha/2}$$

$$\Leftrightarrow n(\bar{x} - \lambda)^2 \le \lambda u^2$$

解这个二次不等式,得

$$\lambda \in \bar{x} + \frac{u_{\alpha/2}^2}{2n} \pm u_{\alpha/2} \sqrt{\frac{\bar{x}}{n} + \frac{1}{4n^2} u_{\alpha/2}^2}$$

设 x_1, \dots, x_n 是从指数总体 $\text{Exp}\{\lambda\}$ 中抽取的一个简单随机样本, 求均值 $\theta = \lambda^{-1}$ 的区间估计。

↑Example

↓Example

解:

可以用随机变量独立和的公式以及归纳法得到 $2\lambda(X_1 + \cdots + X_n) \sim \chi_{2n}^2$, 从而 $2n\lambda \bar{X}$ 可以作为枢轴变量, 并由第 4 条得

$$\theta = \lambda^{-1} \in \left[\frac{\chi_{2n}^2 (1 - \alpha/2)}{2n\bar{x}}, \frac{\chi_{2n}^2 (\alpha/2)}{2n\bar{x}} \right]$$

另一方面, $E(X) = \theta$, $Var(X) = \theta^2$. 当 n 充分大, 由中心极限定理 近似地有

$$\frac{\sqrt{n}(\bar{X} - \theta)}{\theta} \sim N(0, 1),$$

故 $\sqrt{n}(\bar{X}-\theta)/\theta$ 可以作为枢轴变量, 由此得

$$\lambda^{-1} \in \left[\frac{\sqrt{n}\bar{x}}{\sqrt{n}\bar{x} + u_{\alpha/2}}, \frac{\sqrt{n}\bar{x}}{\sqrt{n}\bar{x} - u_{\alpha/2}} \right]$$

11

4.4.2 置信界

在实际中,有时我们只对参数 θ 的一端的界限感兴趣。比如果汁的最低含量,有害物质的最高含量等等.

设总体分布 $F(x,\theta)$ 含有一个未知的参数 θ , $\theta \in \Theta$, 对给定的值 α , $(0 < \alpha < a)$, 若由样本 X_1, \dots, X_n 确定的两个统计量 $\bar{\theta} = \bar{\theta}(X_1, \dots, X_n)$ 和 $\underline{\theta} = \underline{\theta}(X_1, \dots, X_n)$,

1. 若

$$P_{\theta}(\theta \leq \bar{\theta}) \geq 1 - \alpha \quad \forall \ \theta \in \Theta$$

Definition

则称 $\bar{\theta}$ 为 θ 的一个置信系数为 $1-\alpha$ 的置信上界.

2. 若

$$P_{\theta}(\theta \ge \theta) \ge 1 - \alpha \quad \forall \ \theta \in \Theta$$

则称 θ 为 θ 的一个置信水平为 $1-\alpha$ 的置信下界.

而 $(-\infty, \bar{\theta}]$ 和 $[\underline{\theta}, +\infty)$ 都称为是单边的置信区间。寻求置信上、下界的方法和寻求置信区间的方法完全类似。

4.4.3 确定样本大小

在以区间长度为精度准则下,置信区间越窄就越好,为什么呢?作为一个一般的原则,我们已经知道更多的测量可以得到更精确的推断。有时候,对精度是有要求的,甚至于是在测量之前就提出此要求,因此相应的样本大小就要事先确定下来。我们以如下的例子说明如何确定样本大小,一般的方法类似。

假设某种成分的含量服从正态分布 $N(\mu,\sigma^2)$, σ^2 已知。要求平均含量 μ 的 $(1-\alpha)$ 置信区间的长度不能长于 ω 。试确定测量样本大小。

_ ↑Example

↓Example

解: 由于 σ^2 已知,我们已经知道可以根据 $\bar{X}\sim N(\mu,\sigma^2/n)$ 来构造 μ 的 95% 置信区间。因此易知区间长度为 $2u_{\alpha/2}\frac{\sigma}{\sqrt{n}}$. 从而由

$$2u_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le \omega$$

得到

$$n \ge \left(\frac{2u_{\alpha/2}\sigma}{\omega}\right)^2.$$

比如当 $\sigma=0.1, \omega=0.05, \alpha=0.05,$ 可以得到 $n\geq \left(\frac{2\times 1.96\times 0.1}{0.05}\right)^2=61.4656$. 即为达到要求至少需要测量 62 次。