



中国科学技术大学
University of Science and Technology of China

编译和运行系统

《编译原理和技术》

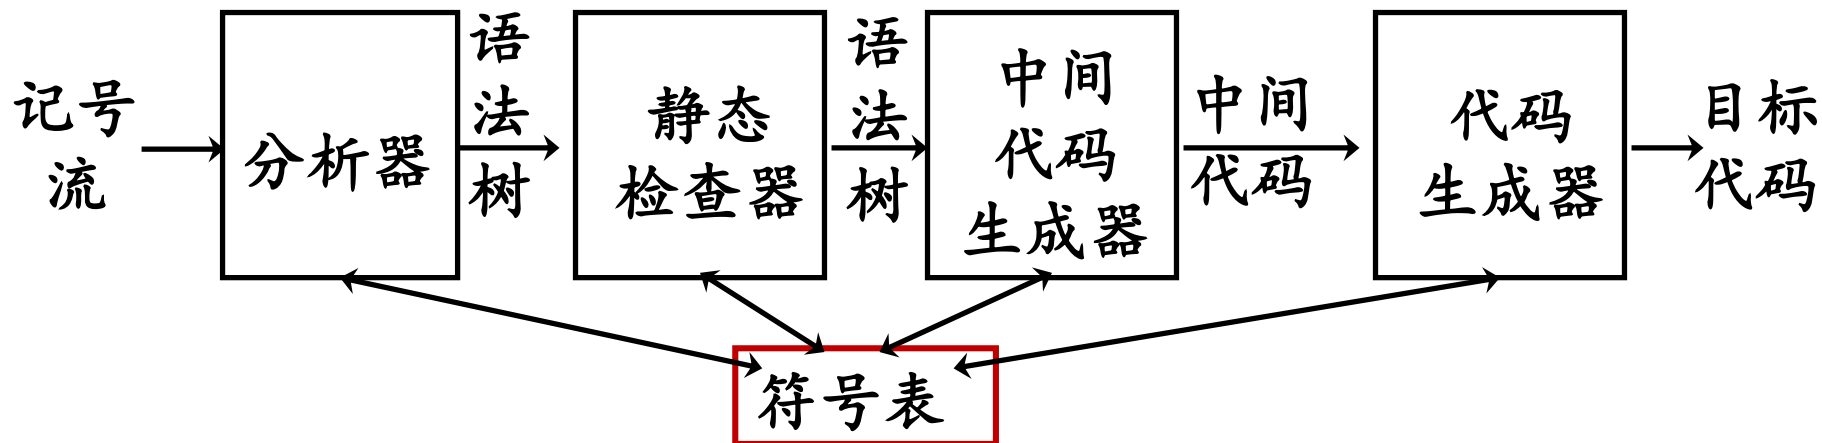
张昱

0551-63603804, yuzhang@ustc.edu.cn

中国科学技术大学
计算机科学与技术学院



本章内容



□ (传统C)编译系统

■ 宏、汇编器、连接器

□ Java运行系统



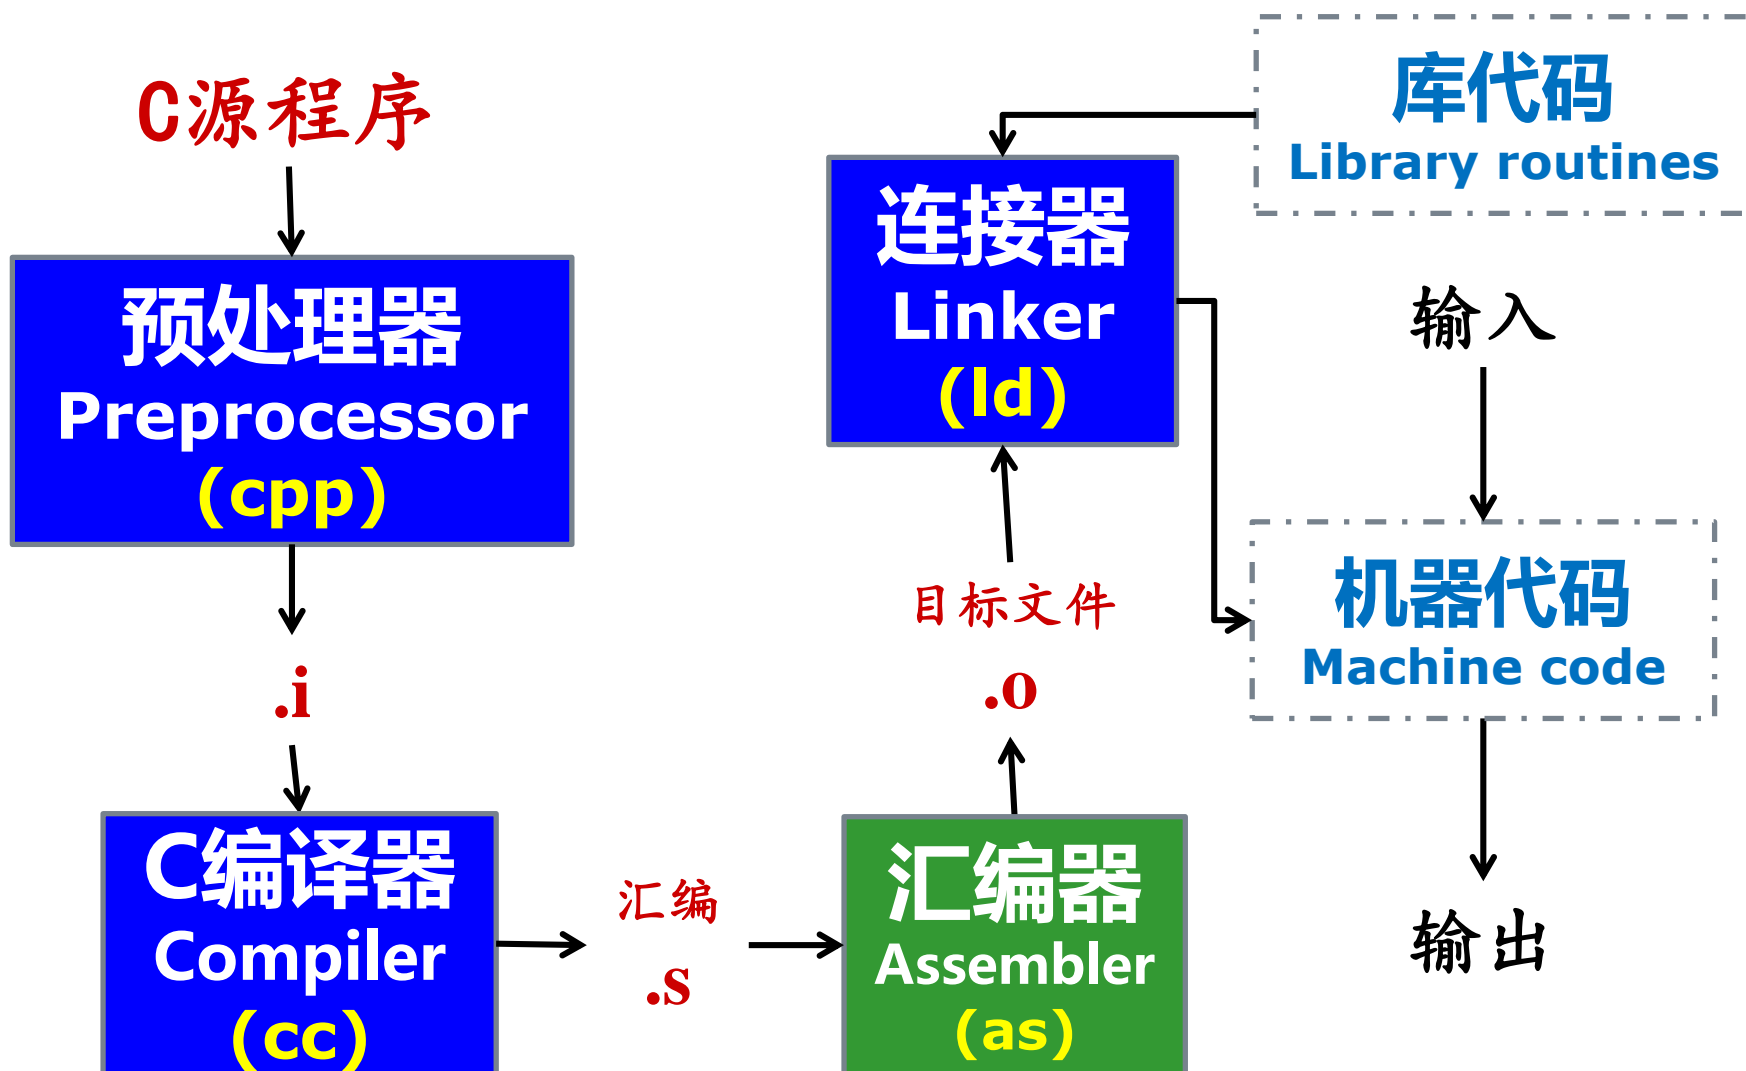
中国科学技术大学
University of Science and Technology of China

1. 编译系统

- ☐ C语言编译系统
- ☐ 宏
- ☐ 汇编器
- ☐ 连接器



C 编译系统





□ GCC: <https://gcc.gnu.org/>

■ 龙芯: <http://www.loongnix.cn/index.php/GCC>

■ 神威: <http://www.nscctx.cn/>

□ Clang/LLVM: <https://llvm.org/>

■ 毕昇编译器: 针对**鲲鹏平台**的高性能编译器

□ 基于LLVM开发

□ 对中端及后端的关键技术点进行了深度优化

□ 集成Auto-tuner特性支持编译器自动调优

■ 龙芯: <http://www.loongnix.cn/index.php/LLVM>

□ 闭源: ICC (oneAPI)



[https://en.wikipedia.org/wiki/Macro_\(computer_science\)](https://en.wikipedia.org/wiki/Macro_(computer_science))

- 词法级别的宏：如C语言
- 语法级别的宏：如类Lisp的语言、Rust、Scala 等
- Hygienic Macro [ESOP2008]

若宏调用处有个名字name1，同时宏内部也有一个name1，hygienic宏在展开时会把自己内部的name1改名成name2
(注：普通宏则不改名)

- Macrofication [ESOP2016]

识别 (JavaScript) 代码中与宏定义的模式相匹配的代码片段，将其替换为宏



```
#define M 10
```

```
#define SWAP(a, b) int t; t=a; a=b; b=t;
```

```
#define SWAP(a,b) {int t; t=a; a=b; b=t;}
```

会有问题吗

宏有哪些用处？
宏定义时需要注意什么？



宏应用举例

□ C语言宏举例：wrapfuns.h 配置文件

```
enum {  
#define fnxx(a, b, c, d) CALL_# #b = d,  
#include "wrapfuns.h"  
    CALLLAST  
};  
#define CALL_ID(k)    CALL_# #k  
#define CALL_NAME(k)  #k  
...  
#define COUNT_CALLS(fn) \  
{  
    \  
    (s_tstat->ncalls[CALL_ID(fn)]) += 1;  
    \  
}
```

用宏定义来描述函数对应的符号常量

配置文件：描述什么样的函数需要统计调用次数、时间等

wrapfuns.h
fnxx(BASIC, spmctime, spmctime, 1)
.....



□ C语言宏举例：wrapfuns.h 配置文件

```
#define BEGIN_TIMING(fn)\
{\
    if ( CALL_ID(fn) > 0 ) {\ \
        COUNT_CALLS(fn) \
        s_tstat->tstart[CALL_ID(fn)] = sys_time();\
    } \
}\
#define END_TIMING(fn) \
{\
    if ( CALL_ID(fn) > 0 ) {\ \
        double t = sys_time()- \
            (s_tstat->tstart[CALL_ID(fn)]);\ \
        s_tstat->calltime[CALL_ID(fn)] += t; \
    } \
}
```



□ C语言宏举例：BEGIN_TIMING等的应用

```
#define _SPMC_DECL1(t1, a1)
#define _SPMC_DECL2(t2, a2, ...)
#define _SPMC_DECL3(t3, a3, ...)
```

```
t1 a1
t2 a2, _SPMC_DECL1(__VA_ARGS__)
t3 a3, _SPMC_DECL2(__VA_ARGS__)
```

参数声明

```
#define _SPMC_ADECL1(t1, a1)
#define _SPMC_ADECL2(t2, a2, ...)
#define _SPMC_ADECL3(t3, a3, ...)
```

```
a1
a2, _SPMC_ADECL1(__VA_ARGS__)
a3, _SPMC_ADECL2(__VA_ARGS__)
```

实参

```
#define SPMC_FUNDEF_RET(x, rettype, fn, ...) \
    rettype \
    swr_##fn(_SPMC_DECL##x(__VA_ARGS__)) { \
        BEGIN_TIMING(fn); \
        rettype r; \
        r = fn(_SPMC_ADECL##x(__VA_ARGS__)); \
        END_TIMING(fn); \
        return r; \
    }
```

用宏定义一大类函数，来对函数调用计时



汇编器

.L2:

cmpl \$0,-4(%ebp)

jne .L6

jmp .L11

.L11:

cmpl \$0,-8(%ebp)

jne .L6

jmp .L12

.L12:

jmp .L5

.p2align 4,,7

.L6:

第一遍扫描建立符号表,
包括代码标号.L2、.L11
等

第二遍扫描依据符号表
中的信息来产生可重定
位代码

gas
llvm-as

一遍扫描完成汇编代码到可重定位目标代码的翻译也是完全可能的（建立标号的回填链）



□ 目标文件形式

- 可重定位的目标文件

- 可执行的目标文件

- 共享目标文件

- 一种特殊的可重定位目标文件

- 在装入程序或运行程序时，动态地装入到内存并连接

□ 连接

收集、组织程序所需的不同代码和数据的过程，以便程序能被装入内存并被执行

ld
gold



□ 连接的时机

- 编译时、装入时，或运行时

□ 静态连接器、动态连接器

□ 符号解析

识别各个目标模块中定义和引用的符号，为每一个符号引用确定它所关联的一个同名符号的定义

- 重定位模块M中可能定义和引用的符号(用nm命令获取)
 - 全局符号(M中定义，可被外部引用)
 - 局部符号(M中定义，只能在M中引用)
 - 外部符号((M外定义，在M中引用)

在C语言中
怎么对应？



□ 连接的时机

- 编译时、装入时，或运行时

□ 静态连接器、动态连接器

□ 符号解析

识别各个目标模块中定义和引用的符号，为每一个符号引用确定它所关联的一个同名符号的定义

- 重定位模块M中可能定义和引用的符号(用nm命令获取)
全局符号(M中定义，可被外部引用)、
局部符号(M中定义，只能在M中引用)、
外部符号((M外定义，在M中引用)

如static全局变量
注意：不是局部变量



使用库的问题举例

□ gcc -S hello.c

没有任何报错和警告

□ gcc -nostdinc -S hello.c

```
#include<stdio.h>
int main()
{
    printf("hello world");
    return 0;
}
```

```
hello.c:1:18: error: no include path in which to search for stdio.h
#include<stdio.h>
      ^
hello.c: In function 'main':
hello.c:4:2: warning: implicit declaration of function 'printf' [-Wimplicit-function-declaration]
    printf("hello world");
    ^~~~~
hello.c:4:2: warning: incompatible implicit declaration of built-in function 'printf'
hello.c:4:2: note: include '<stdio.h>' or provide a declaration of 'printf'
```

编译的什么阶段检查出错误？

预处理阶段：cpp

编译的什么阶段检查出警告？

语义检查（静态类型检查）：cc



使用库的问题举例

- gcc -S hello.c
- gcc -nostdinc -S hello.c
- gcc -nostdlib hello.c

```
#include<stdio.h>
int main()
{
    printf("hello world");
    return 0;
}
```

```
/usr/bin/ld: 警告: 无法找到项目符号 _start; 缺省为 0000000000400144
/tmp/ccvNQfYa.o: 在函数 ‘main’中:
hello.c:(.text+0xf): 对 ‘printf’未定义的引用
collect2: error: ld returned 1 exit status
```

编译的什么阶段检查出警告和错误? 连接阶段: ld

_start是什么? 为什么无法找到它?

_start是程序的入口, 在crt1.o定义 (如位于/usr/lib/x86_64-linux-gnu)

printf为什么是未定义的引用? 因为用nostdlib, 不连接C标准库

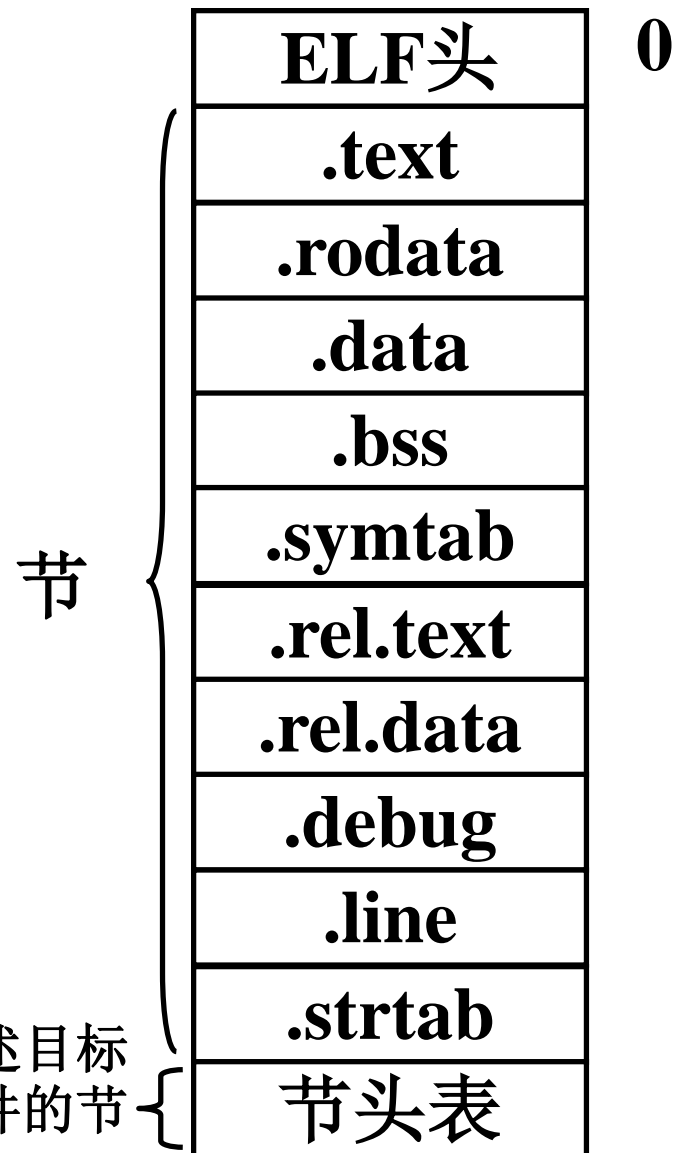


目标文件的格式

□ Unix: ELF

■ ELF头

- 描述了字的大小
- 字节次序
- 目标文件的类型
- 机器类型
- 节头表的位置及条目数
- 其它





目标文件的格式

□ Unix: ELF

■ 节头表

- 描述各节的位置和大小
- 位于目标文件的末尾

■ .text 节

- 被编译程序的机器代码

■ .rodata 节

- 只读数据

■ .data 节

- 已初始化的全局变量

节

描述目标
文件的节

ELF头
.text
.rodata
.data
.bss
.symtab
.rel.text
.rel.data
.debug
.line
.strtab
节头表

0



目标文件的格式

□ Unix: ELF

■ .bss节 (.comm 节)

- 未初始化的全局变量
- 位于目标文件的末尾

■ .symtab 节

- 在该模块中定义和引用的函数和全局变量的信息的符号表
- Type: FUNC, OBJECT
- Bind: GLOBAL, LOCAL, EXTERN
- Value: 地址
- Size: 字节数
- Name

节

描述目标文件的节

ELF头
.text
.rodata
.data
.bss
.symtab
.rel.text
.rel.data
.debug
.line
.strtab
节头表

0



目标文件的格式

□ Unix: ELF

■ .rel.text 节

□ .text 节中需要修改的单元的位置列表
如调用外部函数或引用全局变量的指令

■ .rel.data 节

- 被本模块引用或定义的全局变量的重定位信息
- 要初始化的全局变量

节

描述目标文件的节

ELF头
.text
.rodata
.data
.bss
.symtab
.rel.text
.rel.data
.debug
.line
.strtab
节头表

0



符号解析

□ 解析规则

- 函数和已初始化的全局变量称为**强符号**
- 未初始化的全局变量称为**弱符号**

同名符号的解析

- **不允许**有同名的**多重强符号**定义
- 当出现同名的一个强符号定义和多个弱符号定义时，选择**强符号**的定义
- 出现同名的多个弱符号定义时，选择**任意**一个**弱符号**的定义



□ 静态库

- 将相关的可重定位目标模块打包成一个文件, 作为连接器的输入
- 连接器仅复制库中**被应用程序引用的模块**

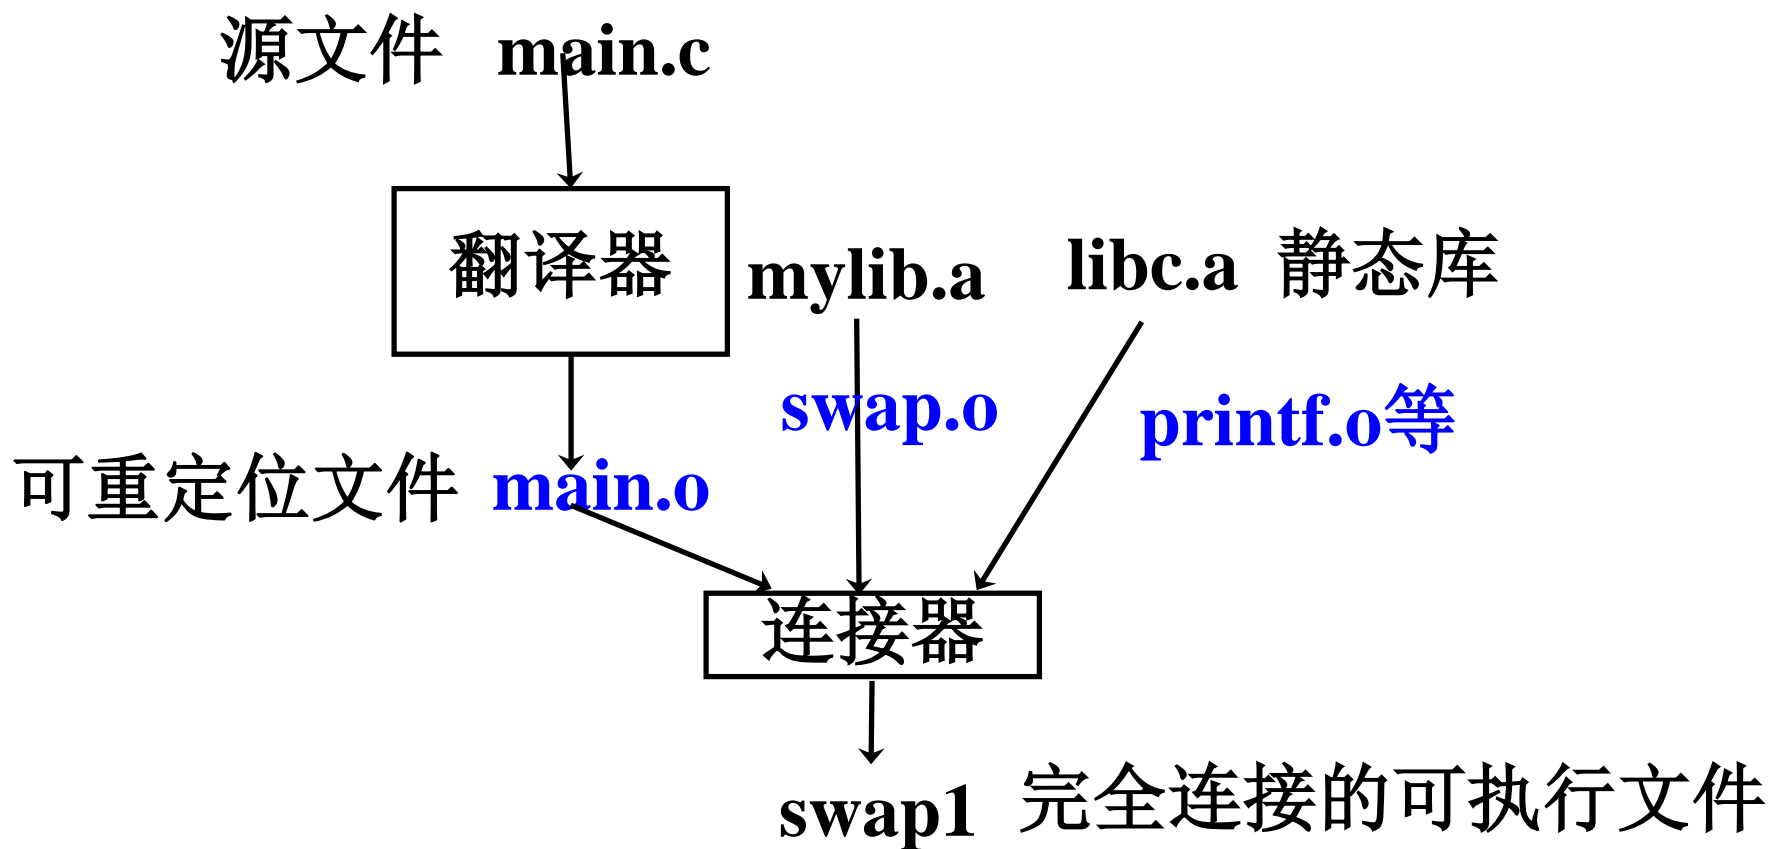
`gcc -c swap.c` —编译

`ar rcs mylib.a swap.o` —建库

`gcc -static -o swap1 main.c /usr/lib/libc.a mylib.a`
—生成可执行文件



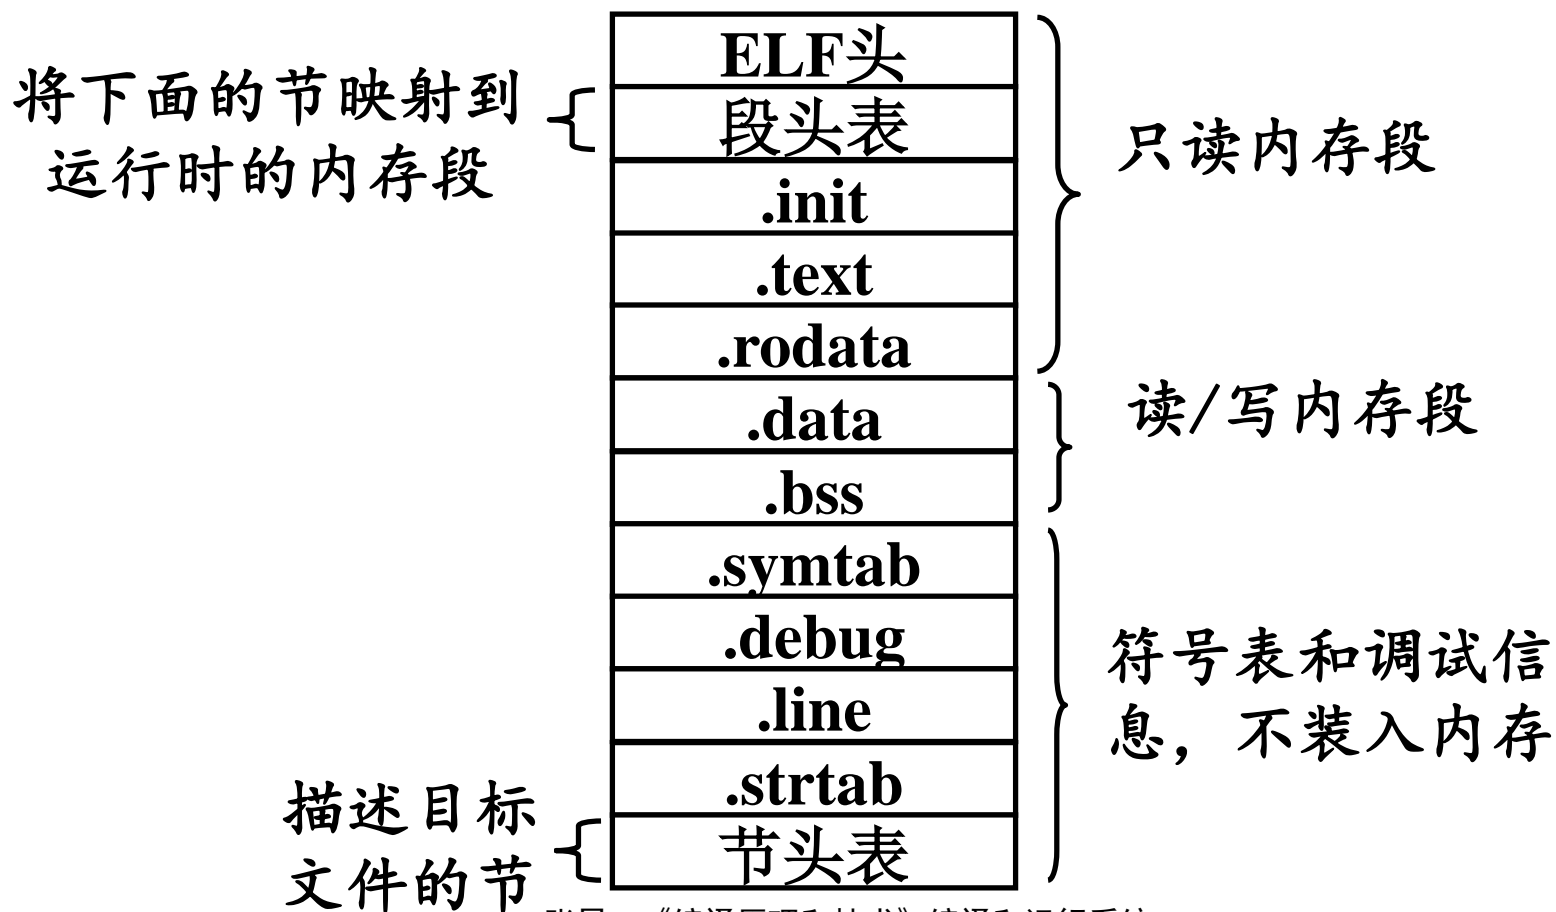
和静态库连接





可执行目标文件及装入

- 可执行目标文件与可重定位目标文件格式类似
- 可执行目标文件的装入由加载器完成





□ 静态库

- 周期性地被维护和更新
- 内存可能有多份printf和scanf的代码

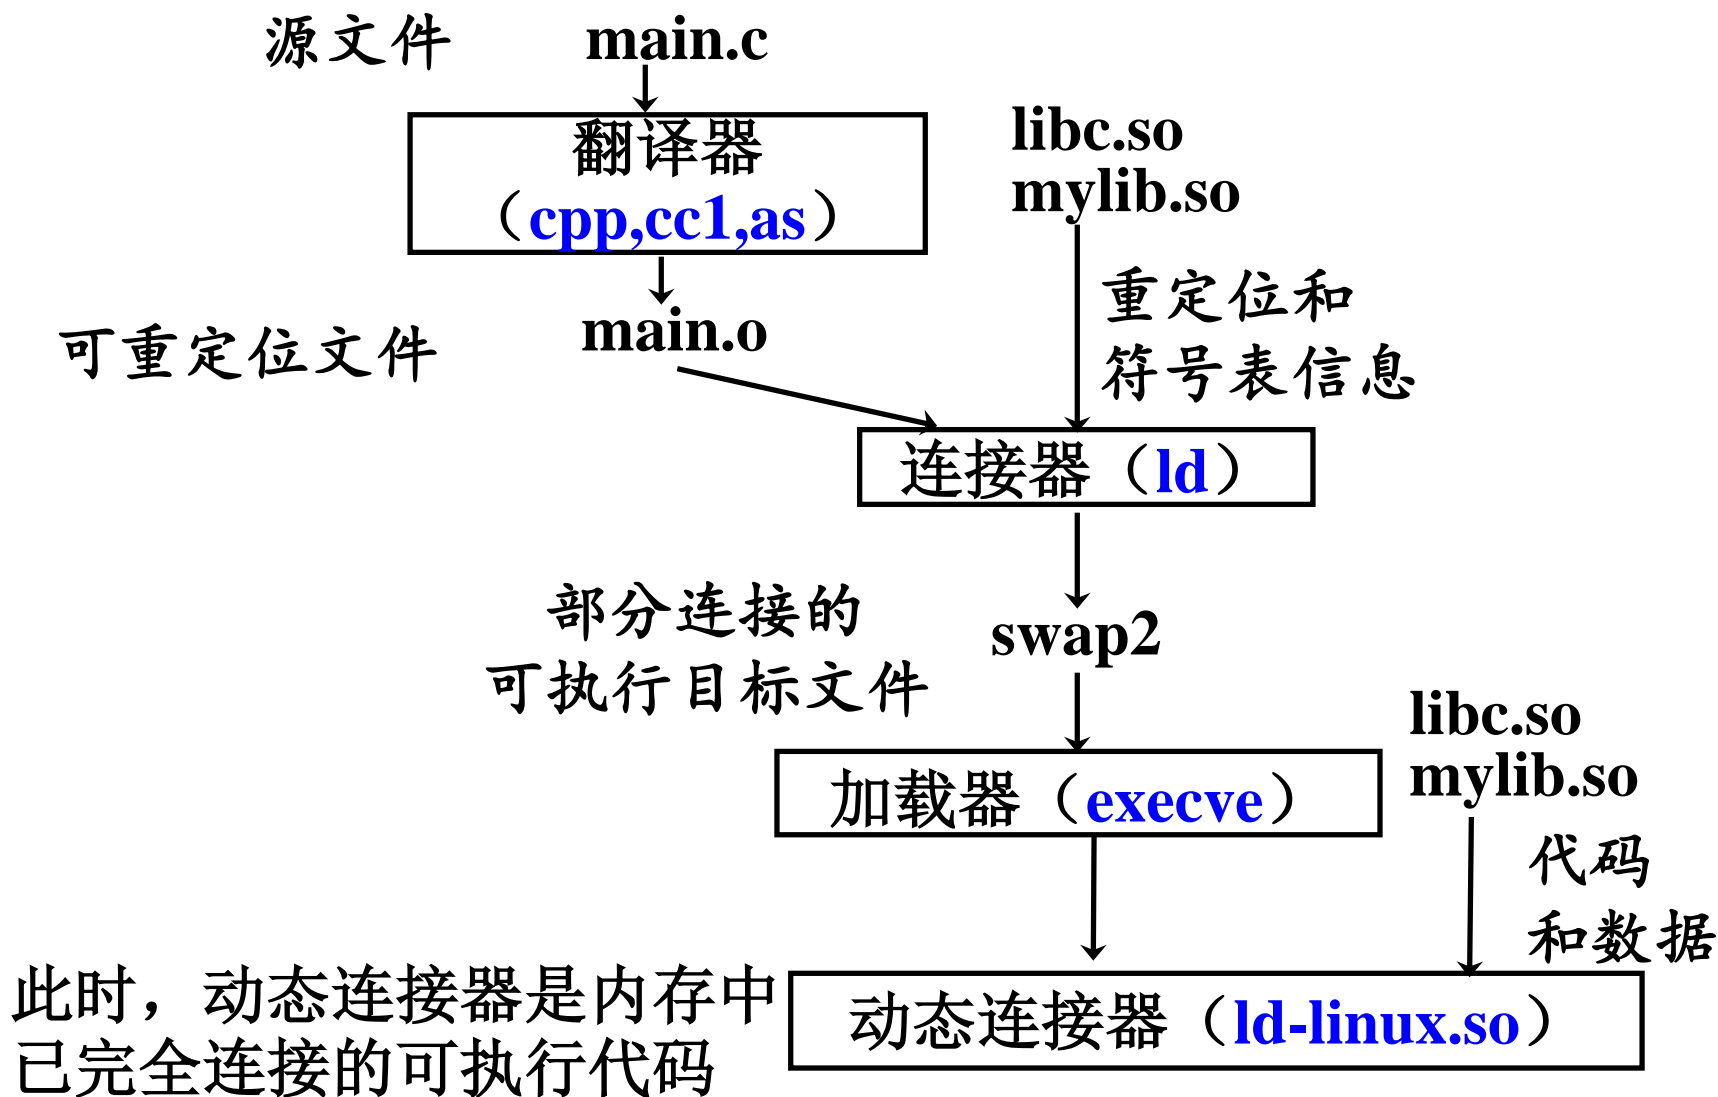
□ 共享库

在运行时可以装到任意的内存位置，被内存中的进程共享

- 共享库的代码和数据被所有引用该库的可执行目标文件所共享
- 共享库的.text节在内存中的一个副本可以被正在运行的不同进程共享




动态连接





□ 经典书籍

- [Linkers & Loaders](#) by John R. Levine, 2000



□ 最近的研究

- [Guided linking: dynamic linking without the costs](#), OOPSLA 2020, UIUC Vikram S. Adve, [ALLVM](#) 项目

- 对于动态链接行为预先已知的，在满足一定约束下，可以将函数内联到其他库中的调用者（**加速**）
- 将跨软件不同部分的相同函数去冗余（**减少代码尺寸**）

<https://github.com/allvm/allvm-tools>



处理目标文件的一些工具

- ar** 创建静态库，插入、删除、罗列和提取成员
- strings** 列出包含在目标文件中的所有可打印串
- strip** 从一个目标文件中删除符号表信息
- nm** 列出一个目标文件的符号表中定义的符号
- size** 列出目标文件中各段的名字和大小
- readelf** 显示目标文件的完整结构，包括编码在ELF头中的所有信息。它包括了**size**和**nm**的功能
- objdump** 可以显示目标文件中的所有信息。其最有用的功能是反汇编.text节中的二进制指令
- ldd** 列出可执行目标文件在运行时需要的共享库



例题1

下面是C语言的一个程序：

```
long gcd(p,q) long p,q; {  
    if (p%q == 0) return q;  
    else return gcd(q, p%q);  
}  
main() {  
    printf("\n%ld\n",gcdx(4,12));  
}
```

在X86/Linux机器上，用gcc命令得到的编译结果如下

In function ‘main’:undefined reference to ‘gcdx’
ld returned 1 exit status.

请问，这个gcdx没有定义，是在编译时发现的，还是在连接时发现的？试说明理由





例题2

C的一个源文件可以包含若干个函数，该源文件经编译可以生成一个目标文件；若干个目标文件可以构成一个函数库

如果一个用户程序引用某函数库中某文件的某个函数，那么，在连接时的做法是下面三种方式的哪一种

- 将该函数的目标代码连到用户程序
- 将该函数的目标代码所在的目标文件连到用户程序 😊
- 将该函数库全部连到用户程序



例题3

`cc`是UNIX系统上C语言编译命令，`-l`是连接库函数的选择项。某程序员自己编写了两个函数库`libuser1.a`和`libuser2.a`（库名必须以`lib`为前缀），当用命令

`cc test.c -luser1.a -luser2.a`

编译时，报告有未定义的符号，而改用命令

`cc test.c -luser2.a -luser1.a`

时，能得到可执行程序。试分析原因

（备注：库名中的`lib`在命令中省略。该命令和命令
`cc test.c libuser1.a libuser2.a`的效果一致）



例题3

cc test.c -luser1.a -luser2.a

解答

test.c

引用a

libuser1.a

定义b

libuser2.a

定义a

引用b



例题4

`cc`是UNIX系统上C语言编译命令，`-l`是连接库函数的选择项。两个程序员分别编写了函数库`libuser1.a`和`libuser2.a`，当用命令

`cc test.c -luser1.a -luser2.a`

编译时，报告有重复定义的符号。而改用命令

`cc test.c -luser2.a -luser1.a`

时，能得到可执行程序。试分析原因



例题4

`cc`是UNIX系统上C语言编译命令，`-l`是连接库函数的选择项。两个程序员分别编写了函数库`libuser1.a`和`libuser2.a`，当用命令

`cc test.c -luser1.a -luser2.a`

编译时，报告有重复定义的符号。而改用命令

`cc test.c -luser2.a -luser1.a`

时，能得到可执行程序。试分析原因

test.c

引用a

引用b

libuser1.a

定义a

libuser2.a

定义b

定义a

a的使用局部于文件，
应加static而未加



例题5

两个C文件link1.c和link2.c的内容分别如下

```
int buf[1]={100};
```

和

```
extern int *buf;
```

```
main() { printf(“%d\n”, *buf); }
```

在X86/Linux经命令cc link1.c link2.c编译后，
运行时产生如下的出错信息

Segmentation fault (core dumped)

请说明原因



例题5

和

```
int buf[1] = {100};      buf: array(1, int)
extern int *buf;         buf: pointer(int)
main() { printf("%d\n", *buf); }
```

类型不同

■ 连接时不检查名字的类型

- 但不同文件分别编译，每个文件对buf有不同的类型

■ 连接时让不同文件中同一名字的地址相同

- 运行时，在link2.c中，由于buf的内容是100，取*buf的值就是取地址为100的单元的内容。该地址不在程序数据区内，报错

■ 若把这些代码放在同一文件中，编译时报错，Why?

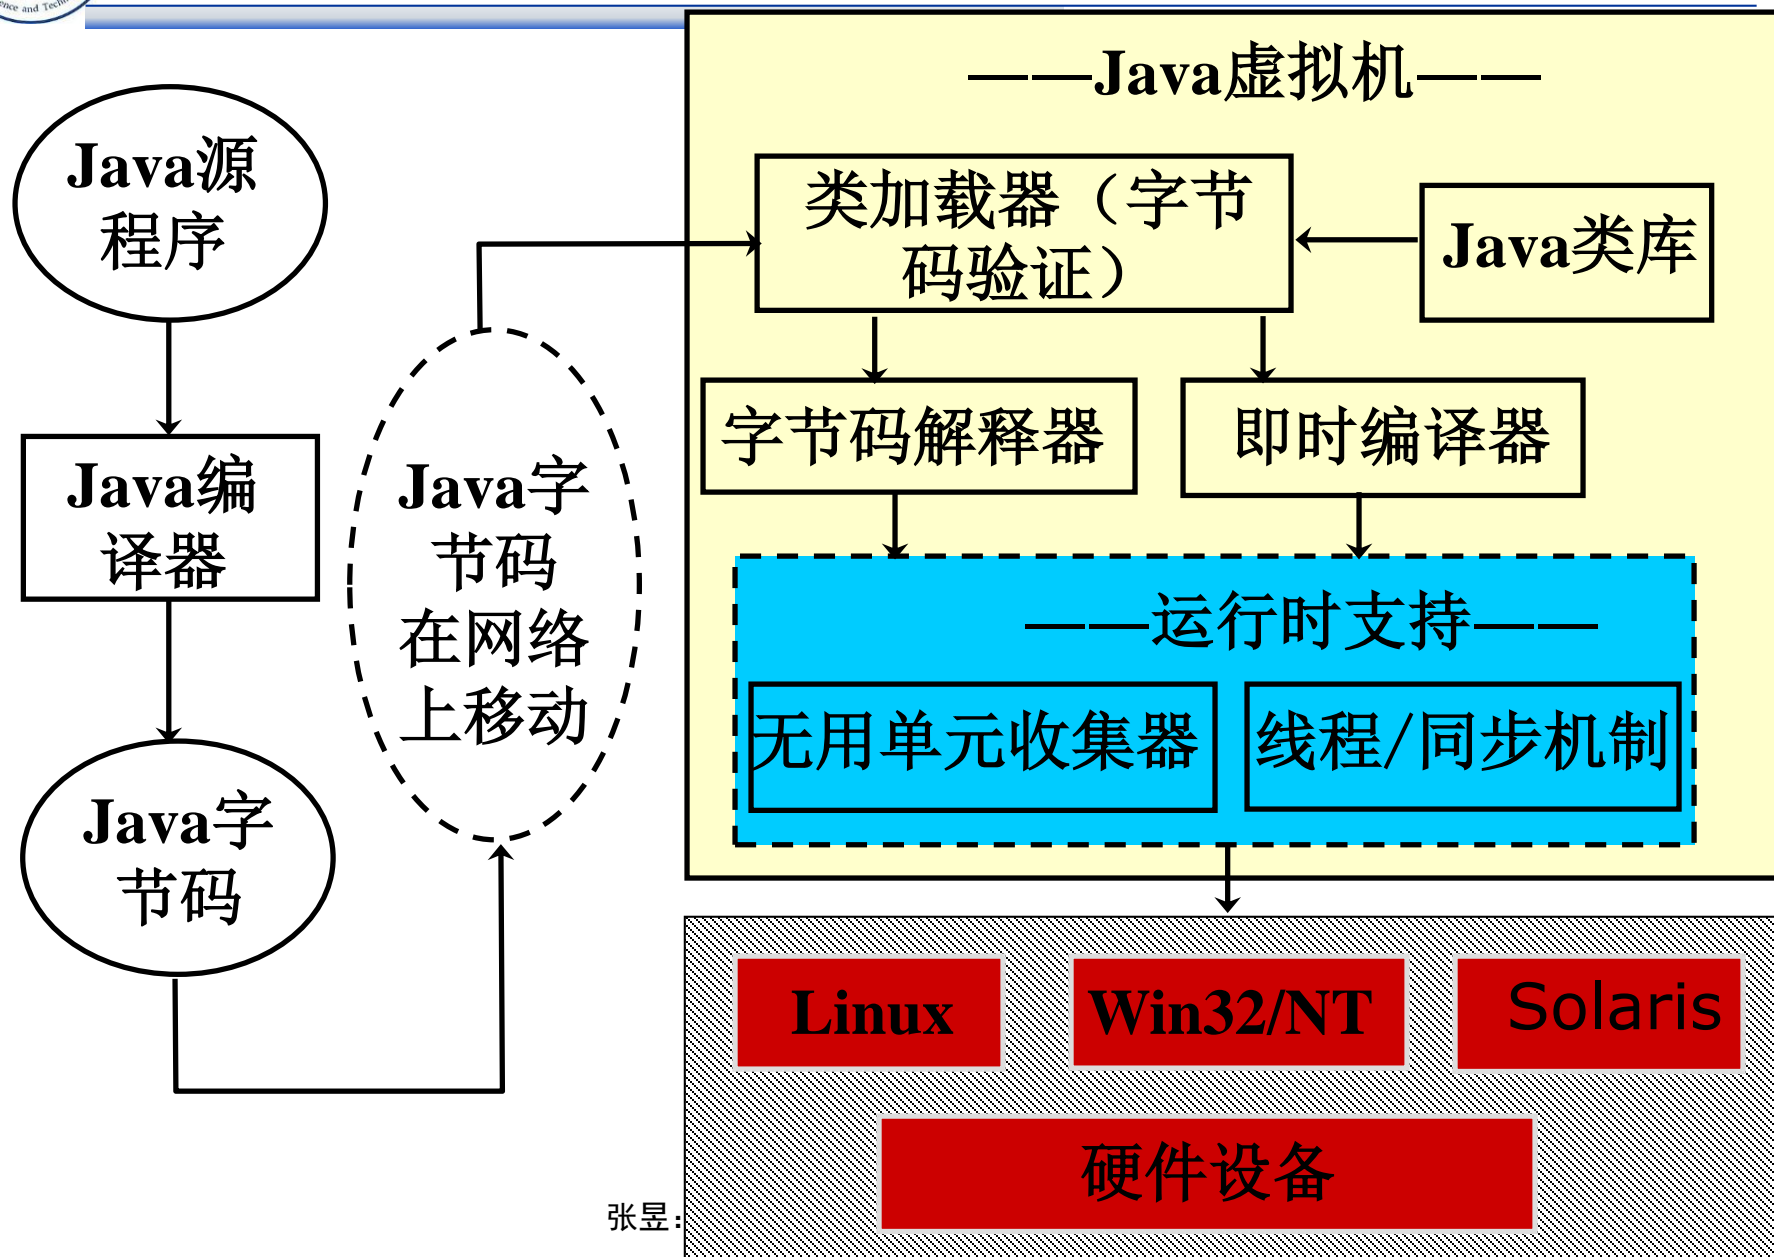


2. Java运行时系统

- ☐ Java虚拟机
- ☐ 无用单元收集
- ☐ 即时编译器



Java虚拟机 (Java运行系统)





□ 编译时机

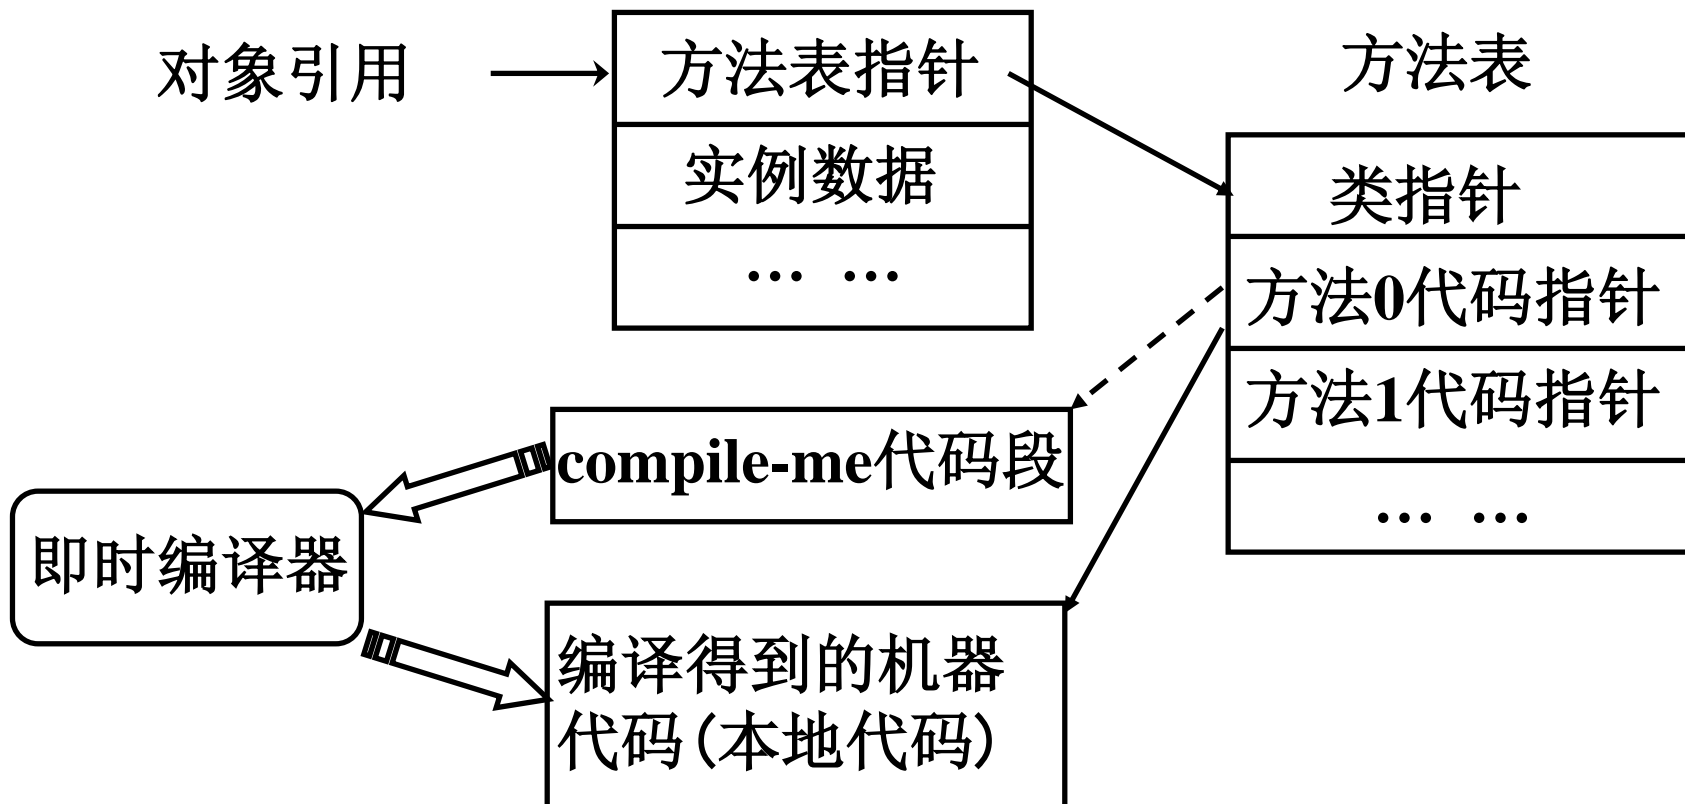
- 当一个类的某个方法第一次被调用时，虚拟机才激活即时编译器将它编译成机器代码

□ 代码性能

- 生成的代码的执行速度可以达到解释执行的10倍
- 但是执行过程不得不等待编译的结束，因而使得执行时间变长

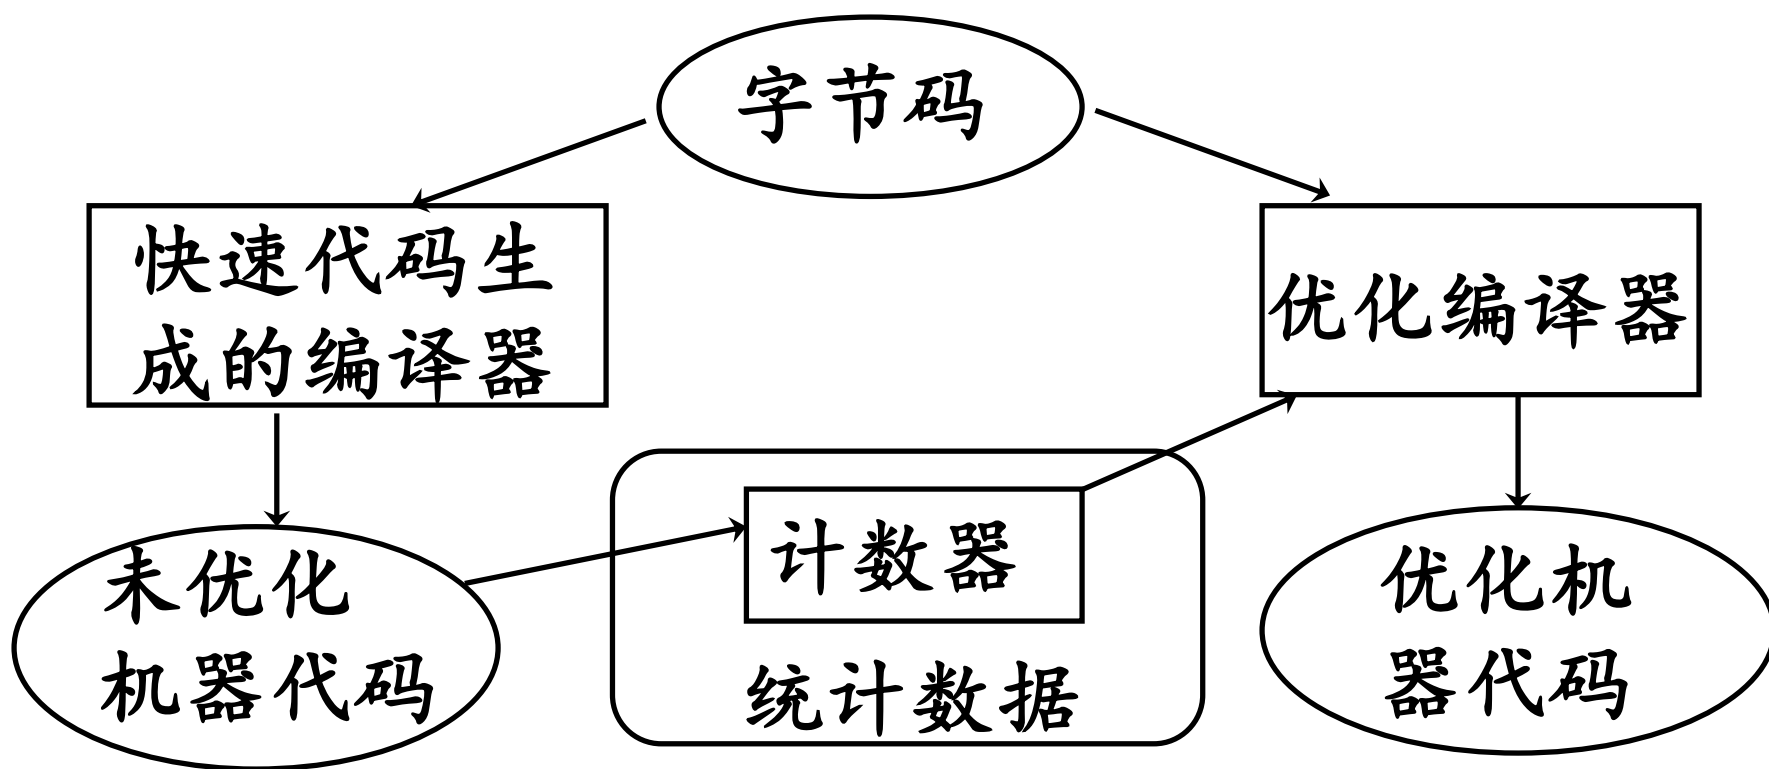
□ 虚拟机的组织

- 很多虚拟机都会使用快速解释器和优化编译器的组合或者是简单编译器和复杂编译器的组合





重编译机制





无用单元收集（俗称垃圾收集）

□ 无用单元（理论上）

- 那些在继续运行过程中不会再使用的数据单元

□ 收集器采用稳妥策略

- 实际上并非总能判断一个数据记录的值以后是否还需要
- 通过根集（*roots set*，在栈上）以及从根集开始的可达性来定义变量的活跃性

□ 无用单元（实现上）

通常指那些不可能从程序变量经指针链到达的堆分配记录



□ 标记和清扫

- 标记堆上所有可达记录：从根集开始图遍历
- 清扫从堆的首地址开始, 寻找未被标记的记录, 把它们链成一个空闲链表

□ 引用计数

□ 拷贝收集

□ 分代收集